权重初始化

1. 全部初始化为零

   实现代码：

```
W = np.zeros(input_layer_neurons, hidden_layer_neurons)
```

   将权重全部初始化为零，每一层所学到的参数一样，因为梯度一样，所以在反响传播过程中，每一层神经元相同。所以会导致代价函数在一开始明显下降，一段时间后停止下降。

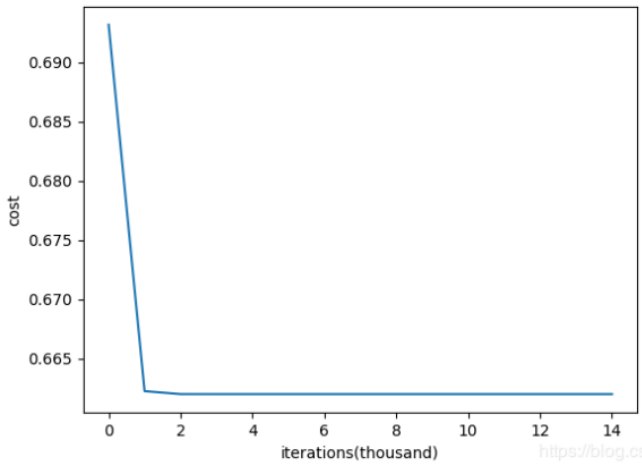

2. 初始化为相同的随机数：

   将权重 w 初始化为相同的随机数与全部初始化为零的效果一样，会出现 Symmetry problem

   实现代码：

```
W = np.zeros(input_layer_neurons, hidden_layer_neurons)*T
```

   随机初始化可以打破对称。在随机初始化后，每个神经元可以继续学习其输入的不同功能。

3. 初始化为较小的随机数

   权重参数随机初始化为服从均值为零和方差为 1 的高斯分布函数

   对于含有n_{in}个输入和$\mathrm{n}_{\mathrm{out}}$个输出的全连接层：

   standard_normal：

$$W_{i,j} \sim N(0, \frac{1}{\sqrt{n_{in}}})$$

   standard_uniform:

$$W_{i,j} \sim N(0, \frac{1}{\sqrt{n_{in}}})$$

   实现代码：

```
W = np.random.randn(input_layer_neurons, hidden_layer_neurons)*0.01
```

   随着时间增加，前向传播时，方差开始减少，梯度也开始向零靠近，会导致梯度消失。当激活函数使用 sigmoid 时，梯度接近 0.5；当激活函数使用 tanh 时，梯度接近 0

4. 初始化为较大的随机数

   实现代码：

```
W = np.random.randn(input_layer_neurons, hidden_layer_neurons)
```

反向传播时，倒数趋于零，梯度也会消失。此外，权重较大且当输入也很大时，如果使用 sigmoid 做激活函数，会使输出趋向于 0 和 1，会导致更多问题。

5. Xavier/Glorot Initialization（适用于激活函数是 softsign 和 tanh）

   条件：正向传播时，激活值的方差保持不变；反向传播时，关于状态值的梯度的方差保持不变，方差：$Var(w) = \frac{2}{n_{in}+n_{out}}$

   初始化方法：（具体推导过程：https://blog.csdn.net/VictoriaW/article/details/73000632、https://blog.csdn.net/freeyy1314/article/details/85029599）

   xavier_normal：

$$W_{i,j} \sim N(0, \sqrt{\frac{2}{n_{in}+n_{out}}})$$

   xavier_uniform：

$$W_{i,j} \sim U(-\sqrt{\frac{6}{n_{in}+n_{out}}}, \sqrt{\frac{6}{n_{in}+n_{out}}})$$

   代码实现：

```
W = np.random.rand（（x_dim, y_dim））* np.sqrt（1 /（ni + no））
```

   注：ni 是输入单元的数量，no 是该层的输出单元的数量。

   限制：在推导过程中假设激活函数在零点附近接近线性函数，且激活值关于 0 对称，而 sigmoid、relu 函数不满足这些假设。

   参考资料：

   [1] Understanding the difficulty of training deep feedforward neural networks Xavier Glorot, Yoshua Bengio ; PMLR 9:249–256

6. MSRA/He initialization（适用于激活函数 relu）

   条件：正向传播时，状态值的方差保持不变；反向传播时，关于激活值的梯度的方差保持不变。

   初始化方法：（具体推导过程：https://blog.csdn.net/VictoriaW/article/details/73166752、）

   he_normal：

$$W_{i,j} \sim N(0, \sqrt{\frac{2}{n_{in}}})$$

   he_uniform：

$$W_{i,j} \sim U(-\sqrt{\frac{6}{n_{in}}}, \sqrt{\frac{6}{n_{in}}})$$

   代码实现：

```
W = np.random.randn（layer_size [1], layer_size [L-1]）* np.sqrt（1 /
layer_size [L-1]）
W = np.random.randn（layer_size [1], layer_size [L-1]）* np.sqrt（2 /
（layer_size [L-1] + layer_size [1]））
```